

Enunciado de Proyecto Final - Reconocimiento de Emociones en el Habla

Conjunto de Datos

La base de datos audiovisual de Ryerson Audio-Visual Database of Emotional Speech and Song ([RAVDESS](#)) incluye grabaciones de 24 actores profesionales (12 mujeres, 12 hombres), quienes vocalizan dos declaraciones léxicamente coincidentes en un acento neutral norteamericano.

El habla incluye expresiones de calma, felicidad, tristeza, enojo, miedo, sorpresa y disgusto.

Cada expresión fue registrada en dos niveles de intensidad emocional (normal y fuerte), con una expresión neutral adicional.

Todas las condiciones están disponibles en tres modalidades:

- solo audio (16bit, 48kHz, .wav),
- audio-video (720p H.264 + AAC 48kHz, .mp4),
- solo video (sin audio).

Tarea fundamental

Desarrollar un sistema de *Speech Emotion Recognition* (SER) capaz de predecir la emoción presente en un audio de voz.

El trabajo deberá incluir:

1. Definición formal de la tarea de clasificación.
2. Diseño y justificación de los splits de entrenamiento, validación y test.
3. Implementación y evaluación de distintos modelos.

La estrategia de división de datos deberá justificarse considerando:

- Posibles variables espurias para la tarea (hablante, texto, intensidad, etc.).
- Cantidad de datos disponibles.
- Escenario de uso esperado del modelo.

- Riesgo de *data leakage*.

Features

Se deberán explorar, como mínimo, las siguientes dos alternativas de representación:

- Features expertas (ver [eGeMAPs](#) features y API de [OpenSmile](#) para Python).
- Embeddings SSL de Audio (wav2vec o WavLM) para transfer learning.

Modelos

Con respecto a los modelos, se deberá:

- Implementar un modelo baseline basado en Random Forest.
- Probar arquitecturas de redes neuronales acordes a la tarea y al formato de las features de entrada.
- Ajustar y justificar hiperparámetros relevantes.

Evaluación y Análisis

Las decisiones experimentales y otros factores (como las métricas utilizadas para evaluar la performance de los modelos) deberán seleccionarse basándose en el estado del arte de la tarea SER.

Además, se deberá incluir una comparación y análisis crítico de los distintos enfoques implementados.

Referencias de Estado del Arte

Se recomienda utilizar como punto de partida los siguientes trabajos:

1. Doğdu, C., Kessler, T., Schneider, D., Shadaydeh, M., & Schweinberger, S. R. (2022). A Comparison of Machine Learning Algorithms and Feature Sets for Automatic Vocal Emotion Recognition in Speech. *Sensors*, 22(19), 7561. <https://doi.org/10.3390/s22197561>
2. Pepino, L., Riera, P., & Ferrer, L. (2021, April 8). Emotion Recognition from Speech Using Wav2vec 2.0 Embeddings. arXiv.org. <https://arxiv.org/abs/2104.03502>

Ideas para extensiones

1. Explorar otras posibles features-embeddings de entrada.

2. Proponer una arquitectura de red neuronal que combine más de un tipo de capa (densa, convolucional, recurrente).
3. Evaluar la performance del modelo sobre otros conjuntos de datos de habla con emociones (como IEMOCAP o EMODB), analizando las principales diferencias de dominio (*domain shift*).
4. Evaluar la performance del modelo sobre audio grabado de manera casera.
5. Probar distintos enfoques de *fine-tuning* partiendo de los modelos SSL.